

K-means 聚类算法研究综述

王 千¹, 王 成², 冯振元¹, 叶金凤³

(1. 69026 部队 新疆 乌鲁木齐 830002; 2. 西安交通大学 航天航空学院, 陕西 西安 710049;

3. 中国建设银行 苏州常熟支行, 江苏 常熟 215500)

摘要: 总结评述了 K-means 聚类算法的研究现状, 指出 K-means 聚类算法是一个 NP 难优化问题, 无法获得全局最优。介绍了 K-means 聚类算法的目标函数、算法流程, 并列举了一个实例, 指出了数据子集的数目 K 、初始聚类中心选取、相似性度量和距离矩阵为 K-means 聚类算法的 3 个基本参数。总结了 K-means 聚类算法存在的问题及其改进算法, 指出了 K-means 聚类的进一步研究方向。

关键词: K-means 聚类算法; NP 难优化问题; 数据子集的数目 K ; 初始聚类中心选取; 相似性度量和距离矩阵

中图分类号: TP391

文献标识码: A

文章编号: 1674-6236(2012)07-0021-04

Review of K-means clustering algorithm

WANG Qian¹, WANG Cheng², FENG Zhen-yuan¹, YE Jin-feng³

(1. 69026 Troop, Urumqi 830002, China; 2. School of Aerospace, Xi'an Jiaotong University, Xi'an 710049, China;

3. Suzhou Changshu Branch, Construction Bank of China, Changshu 215500, China)

Abstract: K-means clustering algorithm is reviewed. K-means clustering algorithm is a NP hard optimal problem and global optimal result cannot be reached. The goal, main steps and example of K-means clustering algorithm are introduced. K-means algorithm requires three user-specified parameters: number of clusters K , cluster initialization, and distance metric. Problems and improvement of K-means clustering algorithm are summarized then. Further study directions of K-means clustering algorithm are pointed at last.

Key words: K-means clustering algorithm; NP hard optimal problem; number of clusters K ; cluster initialization; distance metric

K-means 聚类算法是由 Steinhaus 1955 年、Lloyd 1957 年、Ball & Hall 1965 年、McQueen 1967 年分别在各自的不同的科学研究领域独立的提出。K-means 聚类算法被提出来, 在不同的学科领域被广泛研究和应用, 并发展出大量不同的改进算法。虽然 K-means 聚类算法被提出已经超过 50 年了, 但目前仍然是应用最广泛的划分聚类算法之一^[1]。容易实施、简单、高效、成功的应用案例和经验是其仍然流行的主要原因。

文中总结评述了 K-means 聚类算法的研究现状, 指出 K-means 聚类算法是一个 NP 难优化问题, 无法获得全局最优。介绍了 K-means 聚类算法的目标函数、算法流程, 并列举了一个实例, 指出了数据子集的数目 K 、初始聚类中心选取、相似性度量和距离矩阵为 K-means 聚类算法的 3 个基本参数。总结了 K-means 聚类算法存在的问题及其改进算法, 指出了 K-means 聚类的进一步研究方向。

1 经典 K-means 聚类算法简介

1.1 K-Means 聚类算法的目标函数

对于给定的一个包含 n 个 d 维数据点的数据集 $X=\{x_1,$

$x_2, \dots, x_i, \dots, x_n\}$, 其中 $x_i \in R^d$, 以及要生成的数据子集的数目 K , K-Means 聚类算法将数据对象组织为 K 个划分 $C=\{c_k, i=1, 2, \dots, K\}$ 。每个划分代表一个类 c_k , 每个类 c_k 有一个类别中心 μ_k 。选取欧氏距离作为相似性和距离判断准则, 计算该类内各点到聚类中心 μ_k 的距离平方和

$$J(c_k) = \sum_{x_i \in c_k} \|x_i - \mu_k\|^2 \quad (1)$$

聚类目标是使各类总的距离平方和 $J(C) = \sum_{k=1}^K J(c_k)$ 最小。

$$J(C) = \sum_{k=1}^K J(c_k) = \sum_{k=1}^K \sum_{x_i \in c_k} \|x_i - \mu_k\|^2 = \sum_{k=1}^K \sum_{i=1}^n d_{ki} \|x_i - \mu_k\|^2 \quad (2)$$

其中, $d_{ki} = \begin{cases} 1, & \text{若 } x_i \in c_k \\ 0, & \text{若 } x_i \notin c_k \end{cases}$

显然, 根据最小二乘法和拉格朗日原理, 聚类中心 μ_k 应取为类别 c_k 类各数据点的平均值。

K-means 聚类算法从一个初始的 K 类别划分开始, 然后将各数据点指派到各个类别中, 以减小总的距离平方和。因为 K-means 聚类算法中总的距离平方和随着类别个数 K 的增加而趋向于减小 (当 $K=n$ 时, $J(C)=0$)。因此, 总的距离平方和只能在某个确定的类别个数 K 下, 取得最小值。

收稿日期: 2012-02-13

稿件编号: 201202054

基金项目: 国家自然科学基金资助项目 (10776026)

作者简介: 王 千 (1968—), 女, 吉林九台人, 工程师。研究方向: 人工智能。

1.2 K-means 算法的算法流程

K-means 算法是一个反复迭代过程,目的是使聚类域中所有的样品到聚类中心距离的平方和 $J(C)$ 最小,算法流程包括 4 个步骤^[1],具体流程图如图 1 所示。

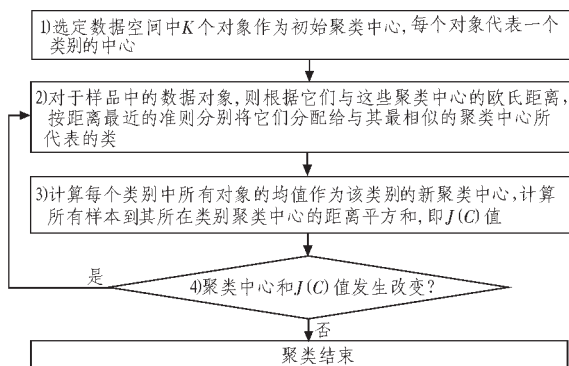


图 1 K-means 聚类算法流程图

Fig. 1 Steps of K-means clustering algorithm




图 2 K-means 算法示意图

Fig. 2 Illustration of K-means algorithm

很多学者指出,如果数据点的维数 $d=1$,最小的总距离平方和 $J(C)$ 值和对应的聚类划分能够在 $O(Kn)^2$ 时间内使用动态规划获得,例如 Bellman and Dreyfus^[4]。Pierre Hansen 等人^[5]认为,K-means 聚类算法时间复杂度未知。

但是,更多的学者认为,对于一般的数据维数 d 和类别个数 K ,K-means 聚类算法是一个 NP 难优化问题^[5]。Sanjoy Dasgupta 等人认为即使在类别个数 $K=2$ 的情况下,K-means 聚类算法也是一个 NP 难优化问题。Meena Mahajan 等人^[6]认

1.3 K-means 聚类算法实例

图 2 显示的是 K-means 算法将一个 2 维数据集集成 3 类的过程示意图。

2 K-means 聚类算法是一个 NP 难优化问题

K-means 聚类算法是一个 NP 难优化问题吗?在某个确定的类别个数 K 下,在多项式时间内,最小的总距离平方和 $J(C)$ 值和对应的聚类划分能否得到?目前,不同的学者有不同的答案。

Aristidis Likas 等人^[2]认为在多项式时间内最小的值和对应的聚类划分能够得到,并于 2002 年提出了全局最优的 K-means 聚类算法。但给出的“The global k-means clustering algorithm”只有初始聚类中心选取的算法步骤,而缺乏理论证明。很快,pierre Hansen 等人^[3]就提出“The global k-means clustering algorithm”不过是一个启发式增量算法,并不能保证得到全局最优,文章最后还给出了反例。

为即使在数据点的维数 $d=2$ 下,对于平面的 K-means 聚类问题,也是 NP 难的。本研究也认为,对于一般的数据维数 d 和类别个数 K ,K-means 聚类算法是一个 NP 难优化问题。K-means 聚类算法是一个贪心算法,在多项式时间内,仅能获得局部最优,而不可能获得全局最优。

3 K-means 聚类算法的参数及其改进

K-means 聚类算法需要用户指定 3 个参数:类别个数 K ,

初始聚类中心、相似性和距离度量。针对这 3 个参数, K-means 聚类算法出现了不同的改进和变种。

3.1 类别个数 K

K-means 聚类算法最被人所诟病的是类别个数 K 的选择。因为缺少严格的数学准则, 学者们提出了大量的启发式和贪婪准则来选择类别个数 K 。最有代表性的是, 令 K 逐渐增加, 如 $K=1, 2, \dots$, 因为 K-Means 聚类算法中总的距离平方和 J 随着类别个数 K 的增加而单调减少。最初由于 K 较小, 类型的分裂(增加)会使 J 值迅速减小, 但当 K 增加到一定数值时, J 值减小速度会减慢, 直到当 K 等于总样本数 N 时, $J=0$, 这时意味着每类样本自成一类, 每个样本就是聚类中心。如图 3 所示, 曲线的拐点 A 对应着接近最优的 K 值, 最优 K 值是对 J 值减小量、计算量以及分类效果等进行权衡得出的结果。而在实际应用中, 经常对同一数据集, 取不同的 K 值, 独立运行 K-means 聚类算法, 然后由领域专家选取最有意义的聚类划分结果。




图 3 J-K 关系曲线

Fig. 3 Relationship curve between J and K

并非所有情况都容易找到 J - K 关系曲线的拐点, 此时 K 值将无法确定。对类别个数 K 的选择改进的算法是 Ball & Hall^[7]于 1965 年提出的迭代自组织的数据分析算法 (Iterative Self-organizing Data Analysis Techniques Algorithm, ISODATA), 该算法在运算的过程中聚类中心的数目不是固定不变的, 而是反复进行修改, 以得到较合理的类别数 K , 这种修改通过模式类的合并和分裂来实现, 合并与分裂在一组预先选定的参数指导下进行。

3.2 初始聚类中心的选取

越来越对的学者倾向于认为最小化总距离平方和 $J(C)$ 值和对应的聚类划分是一个 NP 难优化问题。因此, K-means 聚类算法是一个贪心算法, 在多项式时间内, 仅能获得局部最优。而不同的初始聚类中心选取方法得到的最终局部最优结果不同。因此, 大量的初始聚类中心选取方案被提出。

经典的 K-means 聚类算法的初始聚类中心是随机选取的。Selim S Z, Al-Sultan K S 于 1991 年提出的随机重启 K-means 聚类算法是目前工程中应用最广泛的初始聚类中心选取方法, 其过程如图 4 所示。王成等人提出使用最大最小原则来选取初始聚类中心^[8], 与其它方法不同的是, 该过程是一个确定性过程。模拟退火、生物遗传等优化搜索算法也被用于 K-means 聚类算法初始聚类中心的选取。四种初始聚类中心选取方法的比较可见文献^[9]。自从 Aristidis Likas 等人^[2]提出“The global k-means clustering algorithm”, 对其的批

评^[3]、讨论和改进就没有停止过^[10]。




图 4 多次重启 K-means 聚类算法流程图

Fig. 4 Steps of multiple restarts K-means clustering algorithm

3.3 相似性度量和距离矩阵

K-means 聚类算法使用欧式距离作为相似性度量和距离矩阵, 计算各数据点到其类别中心的距离平方和。因此, K-means 聚类算法划分出来的类别都是类球形的。实际上, 欧式距离是 Minkowski 距离在 $m=2$ 时的特例, 即 L_2 距离。在采用 L_m 距离进行 K-means 聚类时, 最终类中心应是每一类的 m 中心向量。Kashima 等人于 2008 年使用 L_1 距离, 最终聚类中心使每一类的中位向量。对于一维数据集 $X=\{x_1, x_2, \dots, x_i, \dots, x_n\}$ 而言, 中位数 M 比均值 \bar{x} 对异常数据有较强的抗干扰性, 聚类结果受数据中异常值的影响较小。Mao & Jain^[11]于 1996 年提出使用 Mahalanobis 距离, 但计算代价太大。在应用中, Linde 等. 于 1980 年提出使用 Itakura-Saito 距离。Banerjee 等人 2004 年提出, 如果使用 Bregman 差异作为距离度量, 有许多突出优点, 如克服局部最优、类别之间的线性分离、线性时间复杂度等。

4 K-means 聚类算法的其他改进

在 K-means 聚类算法中, 每个数据点都被唯一的划分到一个类别中, 这被称为硬聚类算法, 它不易处理聚类不是致密而是壳形的情形。模糊聚类算法能摆脱这些限制, 这些方法是过去 20 年间集中研究的课题。在模糊方法中, 数据点可以同时属于多个聚类, Dunn 等人^[12]于 1973 年提出了模糊 K-means 聚类算法。

5 结束语

笔者也相信 K-means 聚类是一个 NP 难优化问题, 但这需要更加严格的数学理论证明。因此, K-means 聚类算法是一个贪心算法, 在多项式时间内, 仅能获得局部最优, 对 K-means 聚类算法的研究也将继续。但是对 K-means 聚类算法的研究和改进应注意以下几点:

1) 笔者感兴趣的是现实世界问题的实际解决方案, 模式分析算法必须能处理非常大的数据集。所以, 只在小规模的例子上运行良好是不够的; 我们要求他的性能按比例延伸到大数据集上, 也就是高效算法 (efficient algorithm)。

2) 在现实生活应用中数据里经常混有由于人为误差而引起的噪声。我们要求算法能够处理混有噪声的数据, 并识别近似模式。只要噪声不过多地影响输出, 这些算法应能容忍少量的噪声, 称为算法的健壮性 (robust)。相对于 L_2 距离, L_1 距离有较强的健壮性。但相似性度量和距离矩阵的选取,

不是一个理论问题,而是一个应用问题,需要根据问题 and 应用需要需求,假定合适的模型。例如,采用不同 L_m 的距离,K-means 聚类的结果一般是不同的。

3)统计稳定性即算法识别的模式确实是数据源的真实模式,而不只是出现在有限训练集内的偶然关系。如果我们在来自同一数据源的新样本上重新运行算法,它应该识别出相似的模式,从这个意义上讲,可以把这个性质看作输出在统计上的健壮性。样本读入次序不同,一些聚类算法获得的模式完全不同,而另一些聚类算法对样本读入次序不敏感。从这个角度来讲,最大最小原则比随机重启动、模拟退火、生物遗传在初始聚类中心选取上要更好。

4)K-means 聚类算法的很多变种引入了许多由用户指定的新参数,对这些参数又如何自动寻优确定,是一个不断深入和发展的过程。

5)K-means 还存在一个类别自动合并问题^[1],在聚类过程中产生某一类中无对象的情况,使得得到的类别数少于用户指定的类别数,从而产生错误,能影响分类结果。其原因需要在理论上深入探讨,但这方面的论文和研究很少。聚类的意义,这也是所有的聚类算法都面临的问题,需要在数学理论和应用两方面开展研究。

参考文献:

- [1] Anil K J. Data clustering: 50 years beyond K-Means[J]. Pattern Recognition Letters, 2010, 31(8): 651-666.
- [2] Likas A, Vlassis M, Verbeek J. The global K-means clustering algorithm [J]. Pattern Recognition, 2003, 36(2): 451-461.
- [3] Selim S Z, Al-Sultan K S. Analysis of global K-means, an incremental heuristic for minimum sum-of-squares clustering [J]. Journal of Classification, 2005(22): 287-310.
- [4] Bellman R, Dreyfus S. Applied dynamic programming[M]. New Jersey: Princeton University Press, 1962.
- [5] Aloise D, Deshpande A, Hansen P, et al. NP-hardness of euclidean sum-of-squares clustering [J]. Machine Learning, 2009, 75(2): 245-248.
- [6] Mahajan M, Nimbor P, Varadarajan K. The planar K-means problem is NP-hard [J]. Lecture Notes in Computer Science, 2009(5431): 274-285.
- [7] Ball G, Hall D. ISODATA, a novel method of data analysis and pattern classification[M]. California: Technical rept. NTIS AD 699616. Stanford Research Institute, 1965.
- [8] WANG Cheng, LI Jiao-jiao, BAI Jun-qing, et al. Max-Min K-means Clustering Algorithm and Application in Post-processing of Scientific Computing[C]/Napoli: ISEM, 2011: 7-9.
- [9] Pena J M, Lozano J A, Larranaga P. An empirical comparison of four initialization methods for the K-means algorithm[J]. Pattern Recognition Letters, 1999(20): 1027-1040.
- [10] Lai J Z C, Tsung-Jen H. Fast global K-means clustering using cluster membership and inequality[J]. Pattern Recognition, 2010(43): 1954-1963.
- [11] Mao J, Jain A K. A self-organizing network for hyper-ellipsoidal clustering(hec)[J]. IEEE Transactions on neural networks, 1996(7): 16-29.
- [12] Dunn J C. A fuzzy relative of the isodata process and its use in detecting compact well-separated clusters[J]. Journal of Cybernetics, 1973(3): 32-57.

IDT 推出全球首个真正的单芯片无线电源发送器和最高输出功率单芯片接收器解决方案

拥有模拟和数字领域的优势技术、提供领先的混合信号半导体解决方案的供应商 IDT® 公司(Integrated Device Technology, Inc.; NASDAQ: IDTI)宣布,已推出全球首个真正的单芯片无线电源发送器和业界最高输出功率的单芯片接收器解决方案。与现有解决方案相比,IDT 的高集成多模式发送器可减少 80% 的板面积和 50% 的解决方案材料清单(BOM)成本。更多功能的多模式接收器输出功率为通常使用解决方案的两倍,可将充电时间缩减一半。

IDTP9030 和 IDTP9020 提供了无线电源发送器和接收器解决方案,专为满足无线充电联盟(WPC)的 Qi 标准而设计,可保证与其他满足 WPC Qi 标准器件的互操作性。发送器和接收器均能够进行“多模式”操作,可支持 Qi 标准和专用格式以增加功能、改进安全和提高功率输出能力。内置的协议检测可实现 Qi 与专用模式间的动态转换,从而实现平稳过渡和可靠的用户体验。这些器件可用于大量移动应用以进行便利和轻松的电池充电。

IDTP9030 是如今集成度最高的无线电源发送器。它将大量分立元件的特征和功能结合成一个简单、具有成本效益且高效的解决方案。集成最大程度地将应用面积和元件数量降至最低,让客户可以设计和部署更多紧凑的、具有成本效益和交通便利的无线充电站。这些充电站可在任何地方部署,包括家庭、办公室、图书馆、商店、公共等候区、汽车、机场和飞机座位。

IDTP9020 是一个高效率的单芯片无线电源接收器。在 Qi 模式时,该器件为系统传递高达 5 瓦特。当与 IDTP9030 发送器在专用配置使用时,它可传递高达 7.5 瓦特,让器件适用于强大的移动器件,如平板电脑、智能电话、数码相机、GPS 和耳机。当搭配使用时,IDTP9030 和 IDTP9020 成为业界最有效的端到端无线电源解决方案,可减少能源成本和达到更快的充电时间。

IDTP9020 和 IDTP9030 还拥有专利的多层次异物检测(FOD),利用精密的多参数算法以保证高水平的安全,同时避免 FOD 误报。IDT 的解决方案拥有过温、过压和过流保护,可提供市场上最全面的保护功能,从而保证安全和可靠的操作。此外,当不能使用无线充电站时,接收器还可支持 USB 电缆充电,在移动设备中不再需要 USB 适配器转换器。

咨询编号:2012071002